

Министерство образования Республики Беларусь  
Учреждение образования  
«Брестский государственный технический университет»  
Кафедра ИИТ

Лабораторная работа №1  
По дисциплине: «Основы машинного обучения»  
Тема: «**Знакомство с анализом данных:  
предварительная обработка и визуализация**»

Выполнил:  
Студент 3-го курса  
Группы АС-65  
Кисель М. С.  
Проверил:  
Крощенко А.А.

**Цель работы:** Получить практические навыки работы с данными с использованием библиотек **Pandas** для манипуляции и **Matplotlib** для визуализации. Научиться выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков

## Ход работы

### Общее задание:

1. Загрузить предложенный набор данных (по вариантам) в DataFrame библиотеки Pandas.
2. Провести исследовательский анализ: изучить типы данных, количество пропусков, основные статистические показатели (среднее, медиана, стандартное отклонение).
3. Обработать пропущенные значения (например, заполнить средним значением или удалить строки/столбцы).
4. Преобразовать категориальные признаки в числовые с помощью метода One-Hot Encoding.
5. Выполнить нормализацию или стандартизацию числовых признаков.
6. Построить несколько графиков для визуализации данных (гистограммы, диаграммы рассеяния) и сделать выводы о зависимостях между признаками.

### 7. Написать отчет, создать pull-request в репозиторий с кодом решения и отчетом в формате pdf.

**Используемые инструменты:** Python, Pandas, Matplotlib, NumPy, Jupyter Notebook / Google Colab / PyCharm

### Вариант 8

Выборка Pima Indians Diabetes. Содержит медицинские показатели женщин из племени Пима и информацию о наличии у них диабета.

### Задачи:

1. Загрузите данные и выведите их статистические характеристики.

```
import os
import pandas as pd
#Заголовки в csv-файле(задаем вручную)
columns = [
    "Pregnancies",
    "Glucose",
    "BloodPressure",
    "SkinThickness",
    "Insulin",
    "BMI",
    "DiabetesPedigreeFunction",
    "Age",
    "Outcome"
]

# Загрузка и первичный просмотр данных
os.chdir("d:/Универ/ОМО/ОМО2025/Лаба1/")
df = pd.read_csv("pima-indians-diabetes.csv", comment="#", names=columns, header=None)
print("Первые 5 строк:")
print(df.head())
print("\nИнформация о данных:")
print(df.info())
print("\nСтатистика по числовым признакам:")
print(df.describe())
```

```
Первые 5 строк:
   Pregnancies  Glucose  BloodPressure  SkinThickness  Insulin    BMI  DiabetesPedigreeFunction  Age  Outcome
0            6      148             72           35        0  33.6          0.627     50       1
1            1       85             66           29        0  26.6          0.351     31       0
2            8      183             64           0        0  23.3          0.672     32       1
3            1       89             66           23        94  28.1          0.167     21       0
4            0      137             40           35        35  43.1          2.288     33       1
```

Информация о данных:

```
<class 'pandas.core.frame.DataFrame'>
```

```
RangeIndex: 768 entries, 0 to 767
```

```
Data columns (total 9 columns):
```

#	Column	Non-Null Count	Dtype
0	Pregnancies	768 non-null	int64
1	Glucose	768 non-null	int64
2	BloodPressure	768 non-null	int64
3	SkinThickness	768 non-null	int64
4	Insulin	768 non-null	int64
5	BMI	768 non-null	float64
6	DiabetesPedigreeFunction	768 non-null	float64
7	Age	768 non-null	int64
8	Outcome	768 non-null	int64

```
dtypes: float64(2), int64(7)
```

```
memory usage: 54.1 KB
```

```
None
```

Статистика по числовым признакам:

	Pregnancies	Glucose	BloodPressure	SkinThickness	...	BMI	DiabetesPedigreeFunction	Age	Outcome
count	768.000000	768.000000	768.000000	768.000000	...	768.000000	768.000000	768.000000	768.000000
mean	3.845052	120.894531	69.105469	20.536458	...	31.992578	0.471876	33.240885	0.348958
std	3.369578	31.972618	19.355807	15.952218	...	7.884160	0.331329	11.760232	0.476951
min	0.000000	0.000000	0.000000	0.000000	...	0.000000	0.078000	21.000000	0.000000
25%	1.000000	99.000000	62.000000	0.000000	...	27.300000	0.243750	24.000000	0.000000
50%	3.000000	117.000000	72.000000	23.000000	...	32.000000	0.372500	29.000000	0.000000
75%	6.000000	140.250000	80.000000	32.000000	...	36.600000	0.626250	41.000000	1.000000
max	17.000000	199.000000	122.000000	99.000000	...	67.100000	2.420000	81.000000	1.000000

```
[8 rows x 9 columns]
```

2. Проанализируйте столбцы Glucose, BloodPressure, SkinThickness. Нулевые значения в них, скорее всего, являются ошибками. Замените их медианным значением соответствующего столбца.

```
# Замена скрытых пропусков (нулей) на медиану
cols = ['Glucose', 'BloodPressure', 'SkinThickness']
for c in cols:
    median = df[c].median()
    df[c] = df[c].replace(0, median)
```

3. Постройте гистограммы для признаков BMI и Age.


```
import matplotlib.pyplot as plt
import seaborn as sns

# Визуализация распределений BMI и Age
plt.figure(figsize=(12, 5))

plt.subplot(1, 2, 1)
df['BMI'].hist(bins=20, color='skyblue', edgecolor='black')
plt.title('Распределение BMI')
plt.xlabel('BMI')
plt.ylabel('Количество')

plt.subplot(1, 2, 2)
df['Age'].hist(bins=20, color='salmon', edgecolor='black')
plt.title('Распределение возраста')
plt.xlabel('Возраст')
plt.ylabel('Количество')

plt.tight_layout()
plt.show()
```




4. Создайте матрицу корреляции только для признаков Glucose, BMI, Age и Outcome

```
# Матрица корреляции (Glucose, BMI, Age, Outcome)
subset = df[['Glucose', 'BMI', 'Age', 'Outcome']]
corr = subset.corr()
print("\nМатрица корреляции:")
print(corr)

plt.figure(figsize=(6, 5))
sns.heatmap(corr, annot=True, cmap='coolwarm')
plt.title('Матрица корреляции')
plt.show()
```


**Матрица корреляции:**

	Glucose	BMI	Age	Outcome
Glucose	1.000000	0.235035	0.266909	0.492782
BMI	0.235035	1.000000	0.036242	0.292695
Age	0.266909	0.036242	1.000000	0.238356
Outcome	0.492782	0.292695	0.238356	1.000000



5. Визуализируйте распределение Outcome (наличие диабета) с помощью круговой диаграммы.

```
# Круговая диаграмма распределения Outcome
outcome_counts = df['Outcome'].value_counts()
plt.figure(figsize=(6, 6))
plt.pie(outcome_counts, labels=['Без диабета', 'С диабетом'], autopct='%1.1f%%',
colors=['lightgreen', 'lightcoral'])
plt.title('Распределение наличия диабета')
plt.show()
```



6. Примените стандартизацию ко всем признакам, кроме Outcome.

```
from sklearn.preprocessing import StandardScaler

# Стандартизация признаков (кроме Outcome)
scaler = StandardScaler()
features = df.drop('Outcome', axis=1)
scaled_features = scaler.fit_transform(features)
df_scaled = pd.DataFrame(scaled_features, columns=features.columns)
df_scaled['Outcome'] = df['Outcome']

print("\nСтандартизованные данные:")
print(df_scaled.head())
```

	Стандартизованные данные:										
	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome		
0	0.639947	0.866045	-0.031990	0.831114	-0.692891	0.204013		0.468492	1.425995	1	
1	-0.844885	-1.205066	-0.528319	0.180566	-0.692891	-0.684422		-0.365061	-0.190672	0	
2	1.233880	2.016662	-0.693761	-0.469981	-0.692891	-1.103255		0.604397	-0.105584	1	
3	-0.844885	-1.073567	-0.528319	-0.469981	0.123302	-0.494043		-0.920763	-1.041549	0	
4	-1.141852	0.504422	-2.679076	0.831114	0.765836	1.409746		5.484909	-0.020496	1	