Министерство образования Республики Беларусь
Учреждение образования
«Брестский Государственный технический университет»
Кафедра ИИТ

Лабораторная работа №4
По дисциплине «Основы машинного обучения»
Тема: «Введение в нейронные сети: построение многослойного перцептрона»

Выполнил:
Студент 3 курса
Группы АС-65
Ракецкий П. П.
Проверил:
Крощенко А. А.

Брест 2025

Цель: построить, обучить и оценить многослойный перцептрон (MLP) для решения задачи классификации.

Вариант 4

Общий план для всех вариантов:
1. Импорт библиотек и подготовка данных
• импортируйте torch, torch.nn, torch.optim, а также sklearn для загрузки данных и их предобработки;
• загрузите датасет, выполните стандартизацию (StandardScaler) и кодирование признаков;
• разделите данные на обучающую и тестовую выборки;
• преобразуйте данные (признаки и метки) в тензоры PyTorch: torch.tensor(X_train, dtype=torch.float32).
2. Определение архитектуры нейронной сети
• создайте класс, наследуемый от torch.nn.Module;
• в методе __init__ определите все слои, которые будете использовать (например, nn.Linear, nn.ReLU, nn.Dropout);
• в методе forward опишите последовательность применения слоев к входным данным.
3. Инициализация модели, функции потерь и оптимизатора
• создайте экземпляр вашей модели: model = MLP();
• определите функцию потерь. Для бинарной классификации используйте nn.BCEWithLogitsLoss, для многоклассовой – nn.CrossEntropyLoss;
• определите оптимизатор:
optimizer = torch.optim.Adam(model.parameters(), lr=0.001).
4. Написание цикла обучения (Training Loop)
• запустите цикл на определенное количество эпох;
• внутри цикла:
1. переведите модель в режим обучения: model.train();
2. сделайте предсказание (forward pass):
y_pred = model(X_train);
3. рассчитайте потери (loss):
loss = criterion(y_pred, y_train);
4. обнулите градиенты: optimizer.zero_grad();
5. выполните обратное распространение ошибки:
loss.backward();
6. сделайте шаг оптимизации: optimizer.step().
5. Оценка модели (Evaluation)
• переведите модель в режим оценки: model.eval();
• используйте with torch.no_grad():, чтобы отключить расчет

градиентов;
• сделайте предсказания на тестовых данных;
• преобразуйте выходные данные (логиты) в предсказанные классы (например, с помощью torch.argmax или проверки порога > 0);
• рассчитайте метрики (accuracy, f1-score и т.д.), используя sklearn.metrics.
Вариант 4 Распознавание рукописных цифр
• Digits
• Задача: распознать цифру от 0 до 9 (10 классов).
• Архитектура:
о входной слой;
о один скрытый слой с 32 нейронами (ReLU);
о выходной слой с 10 нейронами (Softmax).
• Эксперимент: сравните результаты с архитектурой, где два скрытых слоя по 32 нейрона. Улучшилась ли точность?

```
import torch
import torch.nn as nn
import torch.optim as optim
from sklearn.datasets import load_digits
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import accuracy_score, f1_score
import numpy as np

# 1. Импорт библиотек и подготовка данных
data = load_digits()
X, y = data.data, data.target

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, ran-
dom_state=42)

scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)

X_train = torch.tensor(X_train, dtype=torch.float32)
X_test = torch.tensor(X_test, dtype=torch.float32)
y_train = torch.tensor(y_train, dtype=torch.long)
y_test = torch.tensor(y_test, dtype=torch.long)

# 2. Определение архитектуры нейронной сети
class MLP(nn.Module):
    def __init__(self, input_size=64, hidden_size=32, num_layers=1):
        super(MLP, self).__init__()
        self.num_layers = num_layers

        self.fc1 = nn.Linear(input_size, hidden_size)
        self.relu = nn.ReLU()

        if num_layers == 2:
            self.fc2 = nn.Linear(hidden_size, hidden_size)
            self.fc3 = nn.Linear(hidden_size, 10)
        else:
            self.fc2 = nn.Linear(hidden_size, 10)

        self.softmax = nn.Softmax(dim=1)
```

```
    def forward(self, x):
        x = self.relu(self.fc1(x))

        if self.num_layers == 2:
            x = self.relu(self.fc2(x))
            x = self.fc3(x)
        else:
            x = self.fc2(x)

        x = self.softmax(x)
        return x

# 3. Инициализация модели, функции потерь и оптимизатора
model_one_layer = MLP(hidden_size=32, num_layers=1)
criterion = nn.CrossEntropyLoss()
optimizer_one = optim.Adam(model_one_layer.parameters(), lr=0.001)

# 4. Написание цикла обучения (Training Loop)
epochs = 1000
for epoch in range(epochs):
    model_one_layer.train()
    optimizer_one.zero_grad()
    outputs = model_one_layer(X_train)
    loss = criterion(outputs, y_train)
    loss.backward()
    optimizer_one.step()

# 5. Оценка модели (Evaluation)
def evaluate_model(model, X_test, y_test):
    model.eval()
    with torch.no_grad():
        outputs = model(X_test)
        _, predicted = torch.max(outputs.data, 1)
        accuracy = accuracy_score(y_test, predicted)
        f1 = f1_score(y_test, predicted, average='weighted')
    return accuracy, f1

acc_one, f1_one = evaluate_model(model_one_layer, X_test, y_test)

print("Модель с одним скрытым слоем:")
print(f"Accuracy: {acc_one:.4f}, F1-score: {f1_one:.4f}")

# Эксперимент: модель с двумя скрытыми слоями
model_two_layers = MLP(hidden_size=32, num_layers=2)
optimizer_two = optim.Adam(model_two_layers.parameters(), lr=0.001)

for epoch in range(epochs):
    model_two_layers.train()
    optimizer_two.zero_grad()
    outputs = model_two_layers(X_train)
    loss = criterion(outputs, y_train)
    loss.backward()
    optimizer_two.step()

acc_two, f1_two = evaluate_model(model_two_layers, X_test, y_test)

print("\nМодель с двумя скрытыми слоями:")
print(f"Accuracy: {acc_two:.4f}, F1-score: {f1_two:.4f}")

print("\nСравнение точности:")
print(f"Accuracy: {acc_one:.4f} -> {acc_two:.4f} (изменение: {acc_two -
acc_one:+.4f})")
```

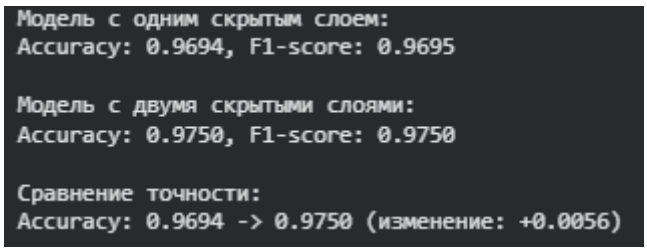

Вывод: построил, обучил и оценил многослойный перцептрон (MLP) для решения задачи классификации.