

Министерство образования Республики Беларусь
Учреждение образования
«Брестский Государственный технический университет»
Кафедра ИИТ

Отчёт по лабораторной работе №3

Выполнил:
Студент 3 курса
Группы АС-65
Романюк Д. А.
Проверил:
Крощенко А. А.

Брест 2025

Цель: На практике сравнить работу нескольких алгоритмов классификации, таких как метод k-ближайших соседей (k-NN), деревья решений и метод опорных векторов (SVM). Научиться подбирать гиперпараметры моделей и оценивать их влияние на результат.

Вариант 5

- Mushroom Classification
- Определить, является ли гриб ядовитым или съедобным
- Задания:
 1. Загрузите данные и преобразуйте все категориальные признаки в числовые (например, с помощью One-Hot Encoding);
 2. Разделите данные на обучающую и тестовую части;
 3. Обучите классификаторы k-NN, Decision Tree и SVM;
 4. Рассчитайте точность и полноту (precision и recall) для класса "ядовитый";
 5. Сделайте вывод о том, какой классификатор лучше всего справляется с этой задачей, где цена ошибки очень высока.

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import OneHotEncoder
from sklearn.neighbors import KNeighborsClassifier
from sklearn.tree import DecisionTreeClassifier
from sklearn.svm import SVC
from sklearn.metrics import precision_score, recall_score, accuracy_score

df = pd.read_csv("mushrooms.csv")

X = df.drop('class', axis=1)
y = df['class']

encoder = OneHotEncoder(sparse_output=False)
X_encoded = encoder.fit_transform(X)

X_train, X_test, y_train, y_test = train_test_split(
    X_encoded, y, test_size=0.3, random_state=42
)

k_values = [1, 3, 5, 7, 9, 11, 15]
k_results = []

for k in k_values:
    model_k = KNeighborsClassifier(n_neighbors=k)
    model_k.fit(X_train, y_train)
    y_pred_k = model_k.predict(X_test)

    acc = accuracy_score(y_test, y_pred_k)
    prec = precision_score(y_test, y_pred_k, pos_label='p')
    rec = recall_score(y_test, y_pred_k, pos_label='p')
```

```

k_results.append((k, acc, prec, rec))

print("=== Сравнение разных значений k ===")
print(f"{'k':<3} | {'Accuracy':<9} | {'Precision':<9} | {'Recall':<9}")
print("-" * 40)
for k, acc, prec, rec in k_results:
    print(f"{'k':<3} | {'acc':<9.4f} | {'prec':<9.4f} | {'rec':<9.4f}")

best_k = max(k_results, key=lambda x: x[3])
print(f"\nОптимальное значение k = {best_k[0]} (Recall = {best_k[3]:.4f})")

models = {
    f"k-NN (k={best_k[0]})":
    KNeighborsClassifier(n_neighbors=best_k[0]),
    "Decision Tree": DecisionTreeClassifier(random_state=42),
    "SVM": SVC(kernel='rbf', random_state=42)
}

results = {}

for name, model in models.items():
    model.fit(X_train, y_train)
    y_pred = model.predict(X_test)

    precision = precision_score(y_test, y_pred, pos_label='p')
    recall = recall_score(y_test, y_pred, pos_label='p')

    results[name] = {'Precision': precision, 'Recall': recall}

print("\n=== Результаты классификаторов ===")
for model_name, metrics in results.items():
    print(f"{model_name}: Precision = {metrics['Precision']:.4f}, Recall = {metrics['Recall']:.4f}")

best_model = max(results.items(), key=lambda x: x[1]['Recall'])
print(f"\nЛучший классификатор по полноте: {best_model[0]}")

```

=== Сравнение разных значений k ===

k	Accuracy	Precision	Recall
1	1.0000	1.0000	1.0000
3	1.0000	1.0000	1.0000
5	1.0000	1.0000	1.0000
7	1.0000	1.0000	1.0000
9	1.0000	1.0000	1.0000
11	0.9996	1.0000	0.9992
15	0.9988	1.0000	0.9975

Оптимальное значение k = 1 (Recall = 1.0000)

=== Результаты классификаторов ===

k-NN (k=1): Precision = 1.0000, Recall = 1.0000

Decision Tree: Precision = 1.0000, Recall = 1.0000

SVM: Precision = 1.0000, Recall = 1.0000

Лучший классификатор по полноте: k-NN (k=1)

Вывод: Все модели показывают почти идеальные результаты, но если выбирать с точки зрения *безопасности* (максимизация Recall для класса “ядовитый”) — лучше взять k-NN.